# 1. Для части по SQOOP

Провести импорт таблицы из вашего сервера БД в Hadoop с использованием SQOOP в любых двух вариантах из перечисленных ниже.

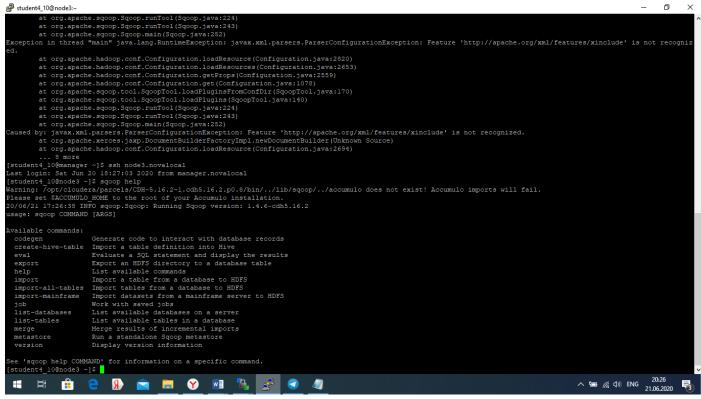
- а. в Hive-таблицу (--hive-import)
- b. в HDFS в формате avro (--as-avrodatafile)
- с. в HDFS в формате sequencefile (--as-sequencefile)

Если у вас нет своего сервера то можно использовать тот Postgres, который я показал на лекции. Пароль expoter\_pass

Посмотрим при помощи SQOOP содержимое в PosgreSQL.

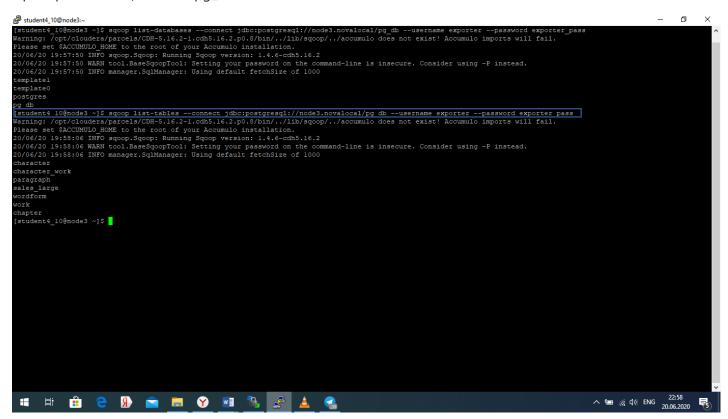
```
### Company | Co
```

Sqoop Help не работает, через ssh перехожу на node3.novalocal



работает!

# Проверим таблицы в базе pg\_db



## Скопируем Таблицу Work в локальную папку

```
student 10@node3 - 1$ sqoop import --connect jdbc:postgresql://node3.novalocal/pg_db --username exporter --password exporter_pass --table work --target-dit_10@node3 - 1$ sqoop import --connect jdbc:postgresql://node3.novalocal/pg_db --username exporter --password exporter_pass --table work --target-dit_10/nv 5/work --as-avroadtafile

Arning; /opt/cloudera/parcels/CDHF-5.16.2-1.cdn5.16.2.pu.8/pin/../lib/sqoop/../accumulo does not exist! Accumulo imports will fail.

Please set $ACCUMULO HOME to the root of your Accumulo instellation.

10/06/21 18:00:45 INFO sqoop.Sqoop: Running Sqoop version: 1.4.6-cdn5.16.2

10/06/21 18:00:45 INFO sqoop.Sqoop: Running Sqoop version: 1.4.6-cdn5.16.2

10/06/21 18:00:45 INFO manager.SqlManager: Using default fetchSize of 1000

10/06/21 18:00:45 INFO manager.SqlManager: Baccuting SQL statement: SELECT t.* FROM "work" AS t LIMIT 1

10/06/21 18:00:45 INFO orm.Compilation/Manager: BACCUMPMENT Sylvo/Loudera/parcels/CDH/lib/hadoop-mapreduce

Note: /tmp/sqoop-student_10/compile/618b15e8a75495be294c889b3e6f1766/work.java uses or overrides a deprecated API.

Note: Recompile with -Xiint:deprecation for details.

10/06/21 18:00:47 INFO orm.Compilation/Manager: Writing jar file: /tmp/sqoop-student_10/compile/618b15e8a75495be294c889b3e6f1766/work.jar

20/06/21 18:00:47 WARN manager.PostgresqlManager: This transfer can be faster! Use the --direct

10/06/21 18:00:47 WARN manager.PostgresqlManager: option to exercise a postgresql-specific fast path.

20/06/21 18:00:47 WARN manager.PostgresqlManager: option to exercise a postgresql-specific fast path.

20/06/21 18:00:47 WARN manager.SpottgresqlManager: option to exercise a postgresql-specific fast path.

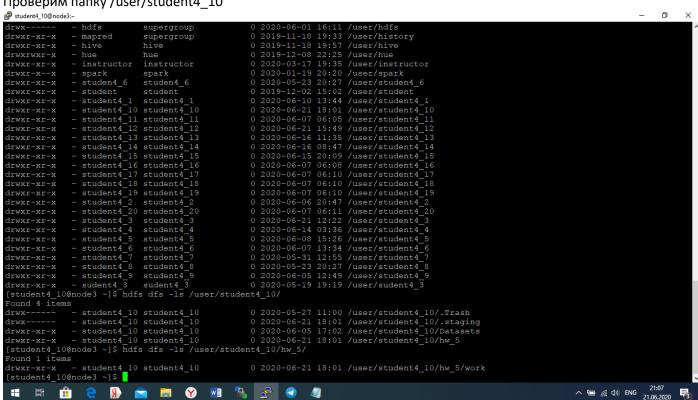
20/06/21 18:00:49 INFO manager.SqlManager: Executing SQL statement: SELECT t.* FROM "work" AS t LIMIT 1

20/06/21 18:00:49 INFO manager.SqlManager: Executing SQL statement: SELECT t.* FROM "work" AS t LIMIT 1

20/06/21 18:00:49 INFO manager.SqlManager: Executing SQL statement: SELECT t.* FROM "work" AS t LIMIT 1

20/06/21 18:00:49 INFO manager.SqlM
                                                                                                                                                                                                                    connect jdbc:postgresql://node3.novalocal/pg_db --username exporter --password exporter pass --table work --target-dir /user/stude
                          i ii 🔒 🧲 🦃 🙀 🙀 🦞 🔞 🥒 🥥
```

# Проверим папку /user/student4\_10



Скопируем схему структуры таблицы с локальной директории через команду COPYFROMLOCAL

```
🧬 student4_10@node3:∼
                                                                                                                                                                                                                                                                                                                                                                                     ₽
[student4] 10@node3 ~]$ hdfs dfs -copyFromLocal work.avsc /us

[student4] 10@node3 ~]$ hdfs dfs -cat /user/student4_10/hw_5/cat: `/user/student4_10/hw_5': Is a directory

[student4_10@node3 ~]$ hdfs dfs -ls /user/student4_10/hw_5/Found 2 items

drwxr-xr-x - student4_10 student4_10 0 2020-06-21

-rw-r--r-- 3 student4_10 student4_10 1368 2020-06-21

[student4_10@node3 ~]$ 11

tota1 32
                                                                                                                                  0 2020-06-21 18:01 /user/student4_10/hw_5/work
1368 2020-06-21 18:21 /user/student4_10/hw_5/work.avsc
  -rw-rw-r--. 1 student4_10 student4_10 1368 Jun 21 18:00 work.avsc
-rw-rw-r--. 1 student4_10 student4_10 25203 Jun 21 18:00 work.java
[student4_10@node3 ~]$ ls
 work.avsc work.java
[student4_10@node3 ~]$ hive
  Java HotSpot(TM) 64-Bit Server VM warning: ignoring option MaxPermSize=512M; support was removed in 8.0
Java HotSpot(TM) 64-Bit Server VM warning: Using incremental CMS is deprecated and will likely be removed in a future release
Java HotSpot(TM) 64-Bit Server VM warning: ignoring option MaxPermSize=512M; support was removed in 8.0
 Logging initialized using configuration in jar:file:/opt/cloudera/parcels/CDH-5.16.2-1.cdh5.16.2.p0.8/jars/hive-common-1.1.0-cdh5.16.2.jar!/hive-log4j.properties
WARNING: Hive CLI is deprecated and migration to Beeline is recommended.
hive> select* from student4_10.work limit 10;
  OK

12 night Twelfth Night Twelfth Night, Or What You Will 1599 c NU

13 night Twelfth Night Twelfth Night, Or What You Will 1599 c NU

14 nilswell All's Well That Ends Well All's Well That Ends Well

15 antonycleo Antony and Cleopatra Antony and Cleopatra 1606 t

16 asyoulikeit As You Like It 1599 c NULL Gomedyerrors Comedy of Errors 1589 c

16 coriolanus Coriolanus Coriolanus 1607 t NULL Mo

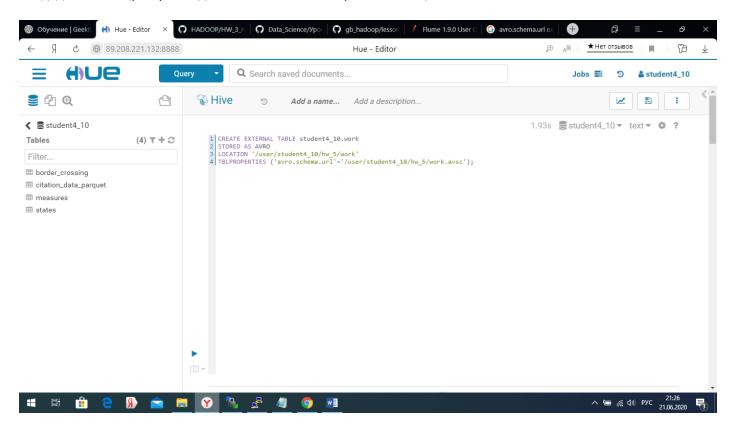
17 cymbeline Cymbeline Cymbeline, King of Britain 1609 t

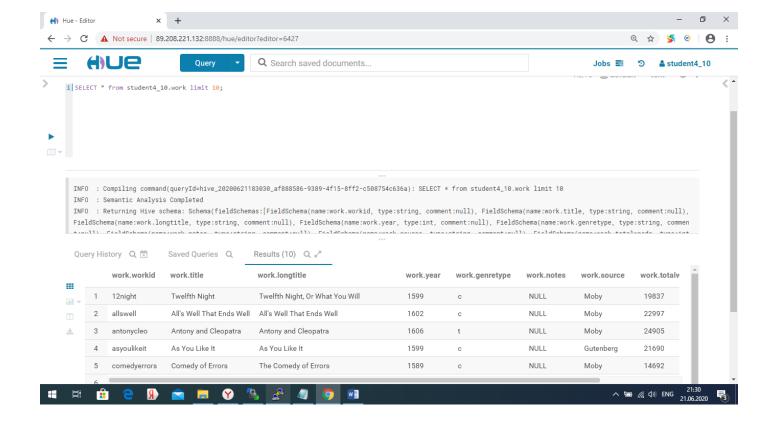
18 nemry4p1 Henry IV, Part I History of Henry IV, Part I 15

18 nenry4p2 Henry IV, Part II History of Henry IV, Part II 15

19 rime taken: 4.499 seconds, Fetched: 10 row(s)
                                                                                                                                                                                                                                        Moby
1602
                                                                                                                                                                                                                                                                                       1031
NULL
                                                                                                                                                                                                                                                                                                              Moby
1344
                                                                                                                                                                                                                                                                Moby
21690
                                                                                                                                                                                                                  Gutenberg
                                                                                                                                                                                                                                         NULL
27577
                                                                                                                                                                                                                                                                Moby
1226
                                                                                                                                                                                                                                                               Moby 27
Gutenberg
                                                                                                                                                                                                                                                                                                                                      1275
884
25692
                                                                                                                                                                                                                                                                                        Moby
   ime taken: 4.499 seconds, Fetched: 10 row(s)
ive> clear
>
                              🔒 🦲 🦻 📹 😯 😘 👺 🐠 🧑 🐠 🛓
```

## Создадим Таблицу с путями для схемы work.avsc и файла таблицы work





Копируем Paragraph Таблицу в формате Parquet, но сначала создадим таблицу так как в Parquet нельзя импортировать таким же способ как avro таблицу , без готовой структуры таблицы в базе данных, так как как не импортируется файл со схемой таблицы

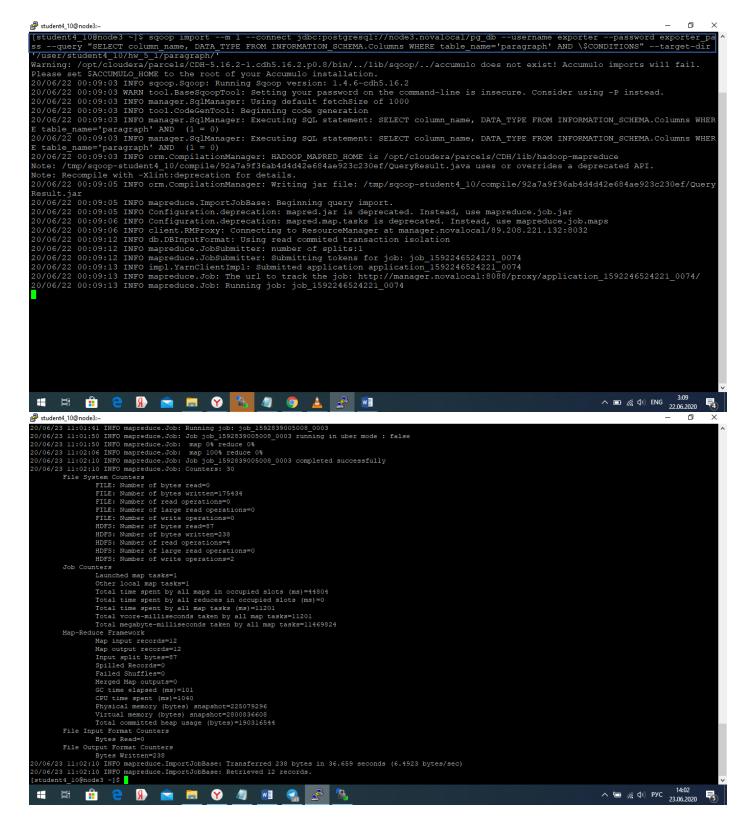
Поэтому через Sqoop проверим схему команды

#### Схема для таблицы work

sqoop import --m 1 --connect jdbc:postgresql://node3.novalocal/pg\_db --username exporter --password exporter\_pass --query "SELECT column\_name, DATA\_TYPE FROM INFORMATION\_SCHEMA.Columns WHERE table\_name='paragraph' AND \\$CONDITIONS" --target-dir '/user/student4\_10/hw\_5\_1/work/'

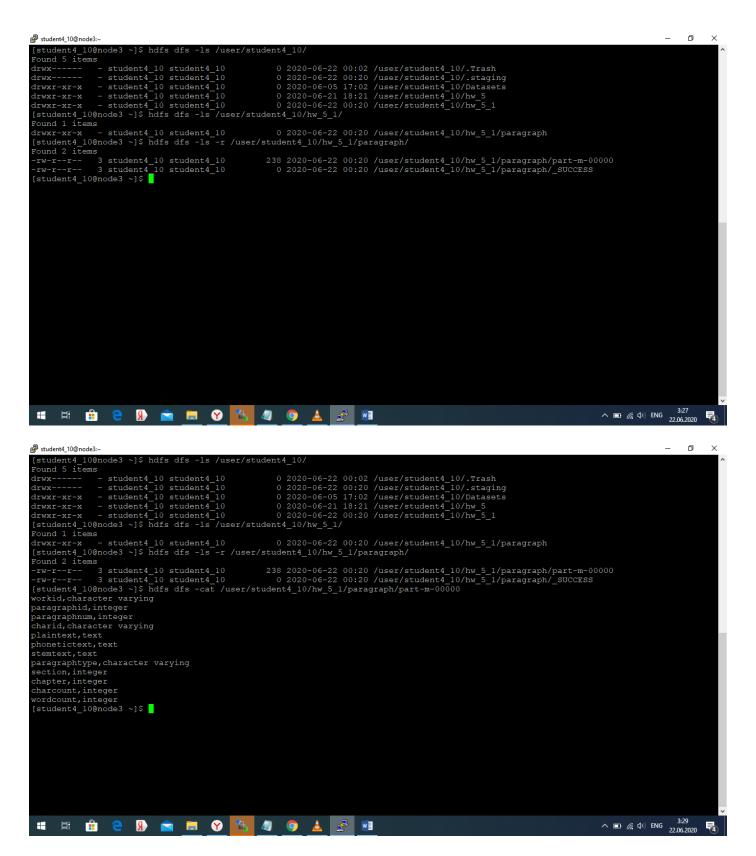
#### Схема для таблицы paragraph

sqoop import --m 1 --connect jdbc:postgresql://node3.novalocal/pg\_db --username exporter --password exporter\_pass --query "SELECT column\_name, DATA\_TYPE FROM INFORMATION\_SCHEMA.Columns WHERE table\_name='paragraph' AND \\$CONDITIONS" --target-dir '/user/student4\_10/hw\_5\_1/paragraph/'

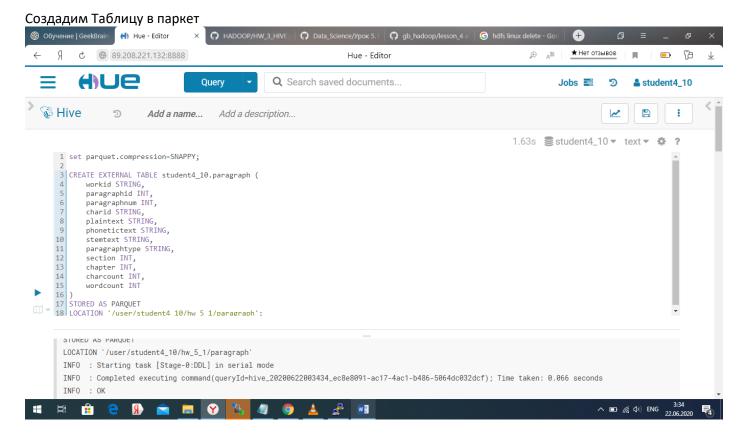


Добавил snapshot полного лога

Проверим что импортировалось с базы PG\_DATABASE (таблица параграф)



В схеме указаны колонки с типами данных



### Импортируем данные в таблицу

sqoop import --connect jdbc:postgresql://node3.novalocal/pg\_db --username exporter --password exporter\_pass -- table paragraph --hive-import --hive-database student4\_10 --hive-table paragraph\_1 --as-parquetfile

```
## windered. 100models.

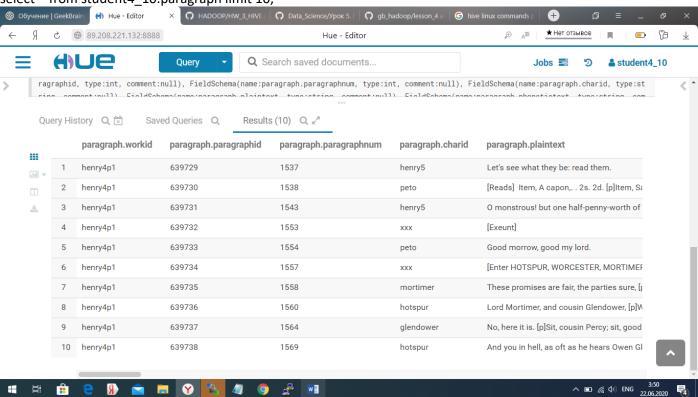
| Phonesictext, text | phonesictext, text | paragraphtype, character varying | section, integer | chapter, integer | chap
```

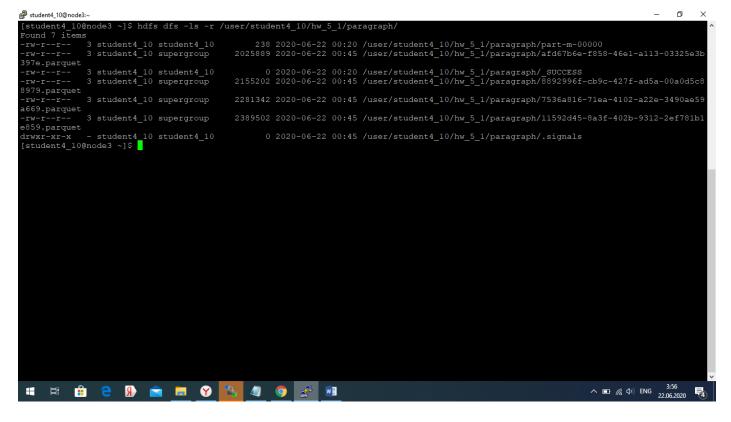
```
### Comparison of the Comparis
```

Скриншоты лога

## Делаем проверку

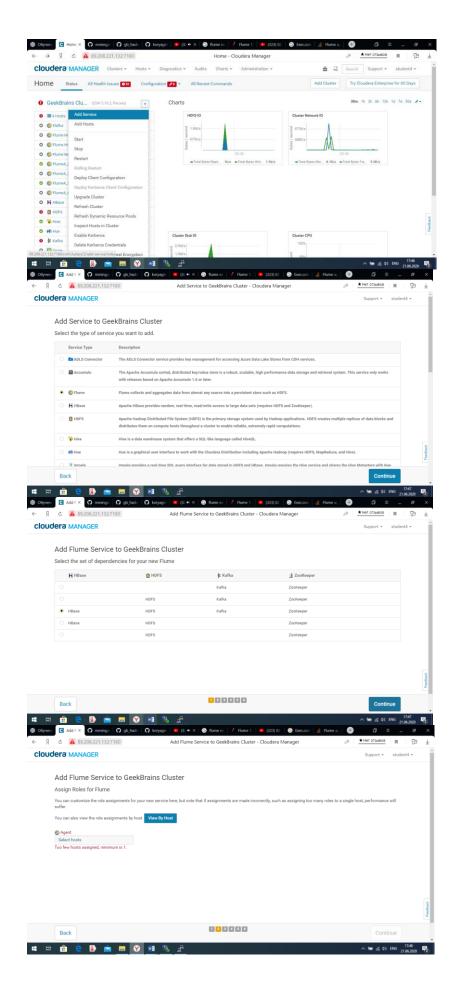
select \* from student4\_10.paragraph limit 10;

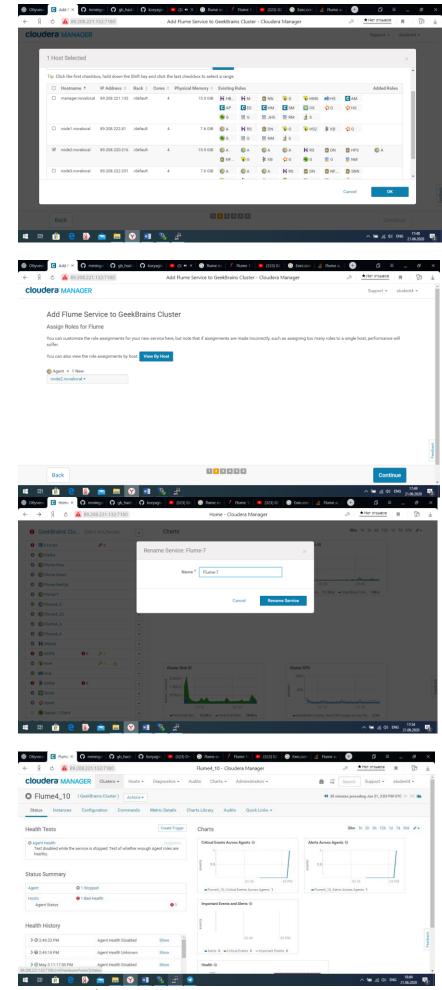




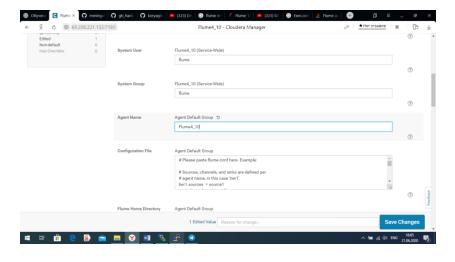
Точно таким способом можно выполнить работу и с Avro файлом

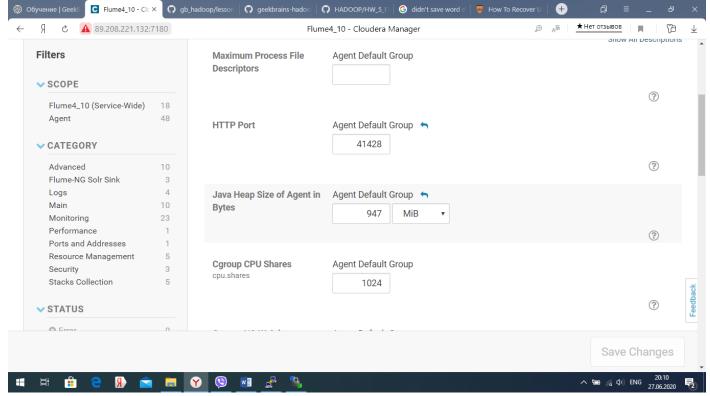
- 1.Создать Flume-агент с именем, соответствующим имени своего пользователя (например Flume4\_20)
- 2. Создать любой Flume поток используя Flume сервис соответствующего номера.
- Тип источника источник ехес
- Тип канала memory
- Тип слива hdfs
- 3. Убедиться что данные поступают в слив.
- 4. Создать поверх данных в hdfs таблицу через которую можно просмотреть полученные данные.
- 5. [Продвинутый вариант] Сделать то-же самое используя несколько сливов в разные места, например в HDFS и в HIve одновременно
- 6. [Продвинутый вариант] Повторить стандартный пример с выборкой сообщений из Twitter.
- 1.Создать Flume-агент с именем, соответствующим имени своего пользователя (например Flume4 20)





BAD HEALTH!





Поменяем лог на 41428

- 2. Создать любой Flume поток используя Flume сервис соответствующего номера.
- Тип источника источник ехес
- Тип канала memory
- Тип слива hdfs

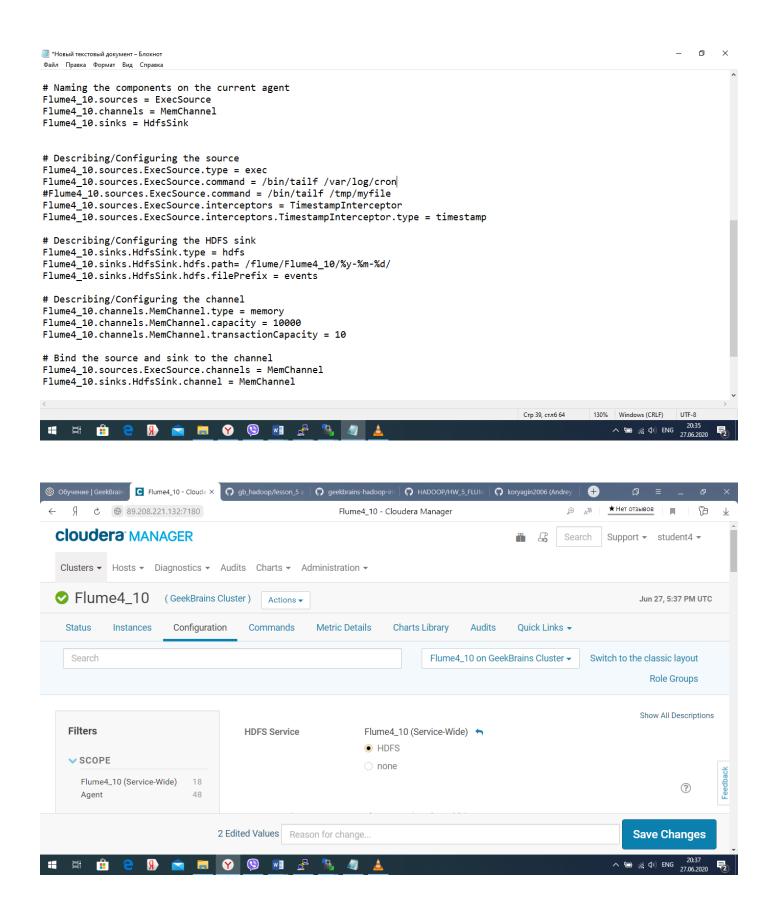
## работает с этим лог файлом

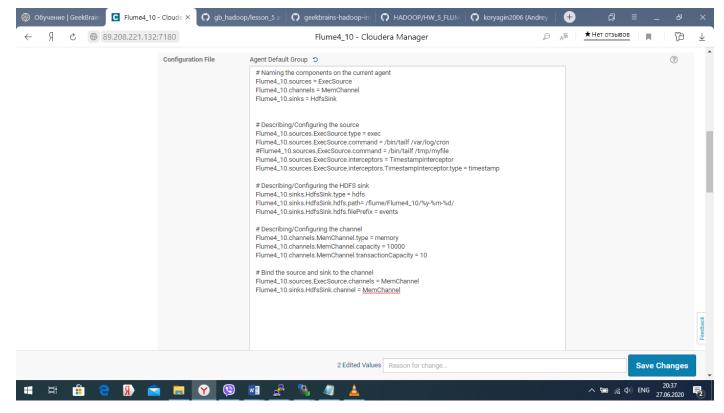
## Var/log/cron

Создадим новую папку в разделе FLUME под именем Flume4\_10

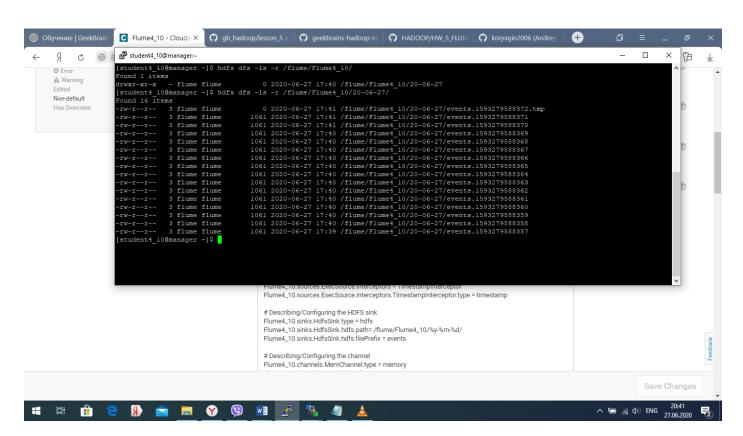
```
### Company | 10 bads offs -1s /flume/
| Faundant | 10 bads offs -1s /
```

Код для FLUME

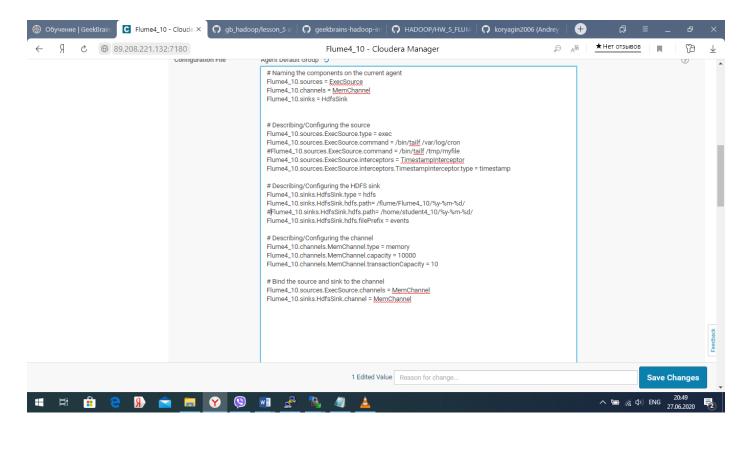


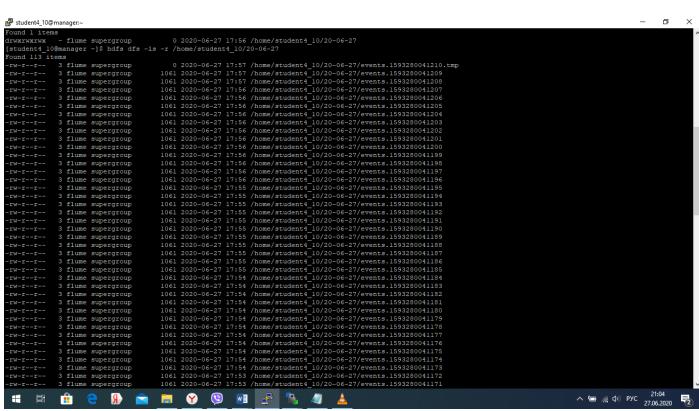


Заполняем кодом, потом сохраняем и запускаем Flume4 10



Проверяем содержимое в папке flume





## Вопрос

По поводу прав для того чтобы делать SINK и SOURCE с файлами FLUME я должен иметь права на папки в директории как student4\_10,

другими словами я не совсем понимаю какие права должны быть у FLUME agent а какие у STUDENT4\_10

А вот в каких случаях Flume должен иметь права, так как HADOOP\_USER\_NAME не нужен если ты работаешь за приделами папки FLUME

[student4\_10@manager ~]\$ export HADOOP\_USER\_NAME=flume [student4\_10@manager ~]\$ hdfs dfs -mkdir /home/student4\_10/new [student4\_10@manager ~]\$ ls /students/student4\_10/ mapper.py reducer.py